

# Proyecto: RainWise

Equipo: Tlaloc Rainkeepers

Juan Angel López Delgadillo [juan.lopez@cimat.mx](mailto:juan.lopez@cimat.mx)  
, Luis Osvaldo Cerna Copado [luis.cerna@cimat.mx](mailto:luis.cerna@cimat.mx)  
, Emilio Alejandro Pérez Cerrillo [ea.perezcerrillo@ugto.mx](mailto:ea.perezcerrillo@ugto.mx)  
, Itzanami Berlanga Contreras [itzanami.berlanga@gmail.com](mailto:itzanami.berlanga@gmail.com)

*Aqua Challenge - Talent Land España 2024.*

*Repositorio del proyecto: <https://github.com/miloperez/RainWise>*

julio, 2024

## Descripción.

Plataforma Web interactiva impulsada por modelos de deep learning que predice sequías a largo plazo y arroja zonas potencialmente aprovechables para la captación de agua de lluvia utilizando imágenes satelitales y datos públicos. Analiza las diversas crisis hídricas por región y ofrece recomendaciones tanto a la industria como a la población. Las recomendaciones están enfocadas en identificar potenciales ubicaciones para la instalación de sistemas de recolección pluviales, optimizando la gestión del recurso en la región y obteniendo un ahorro de agua para la población e industria.

## 1. Introducción.

El **cambio climático** es un fenómeno que se manifiesta de maneras cada vez más impactantes, como se ha podido evidenciar en el aumento de temperaturas, siendo 2023 el año más cálido registrado hasta el momento. Esto ha causado la disminución de recursos disponibles necesarios para la subsistencia humana.

Las sequías son períodos prolongados de tiempo seco causado por la falta de lluvia, lo que produce escasez de agua. Sin embargo, las sequías no son únicamente provocadas por la falta de lluvia, sino que la acción humana y la pésima gestión del agua en diversas regiones del planeta han causado desabastecimiento a los ecosistemas, poblaciones, y a generado problemas de salud pública. Las sequías dominan la lista de catástrofes de los últimos 50 años, tanto en términos de pérdidas humanas como económicas, según un análisis exhaustivo de la **Organización Meteorológica Mundial (OMM)**.

Según datos del **Instituto Nacional de Estadística y Geografía (INEGI)**, la industria manufacturera es la que consume la mayor cantidad de agua en México, representando el 74.5% del total de agua utilizada por la industria. Otros sectores que utilizan grandes cantidades de agua incluyen la minería, la generación de energía, la construcción y la agricultura.

Sequías, tormentas e inundaciones: el agua y el cambio climático dominan la lista de desastres

• Visto: 63571



La mitad de los daños humanos y económicos causados por catástrofes en los últimos cincuenta años están relacionados con el agua y el clima. Solo los desastres relacionados con el agua han causado cerca de 1,3 millones de personas fallecidas y representan el 50% de todas las catástrofes.

**Figura 1:** El agua y el cambio climático dominan la lista de desastres (**ONU**)

Se definen cuatro tipos de sequía: **meteorológica, hidrológica, agrícola y socio-económica**. La sequía meteorológica es definida mediante la falta de humedad o sequedad comparado con una media y la duración del periodo en que se presenta. Por su parte, la sequía agrícola enlaza los impactos de la sequía meteorológica enfocada a los efectos que tiene en el campo agrícola, especialmente el déficit de precipitación y escasez de agua en el suelo. La sequía hidrológica hace referencia al impacto de la falta de precipitación con el abastecimiento de agua, ya sea superficial o subterránea. Por último, la sequía socio económica se refiere a la asociación de los efectos de los tres tipos anteriores

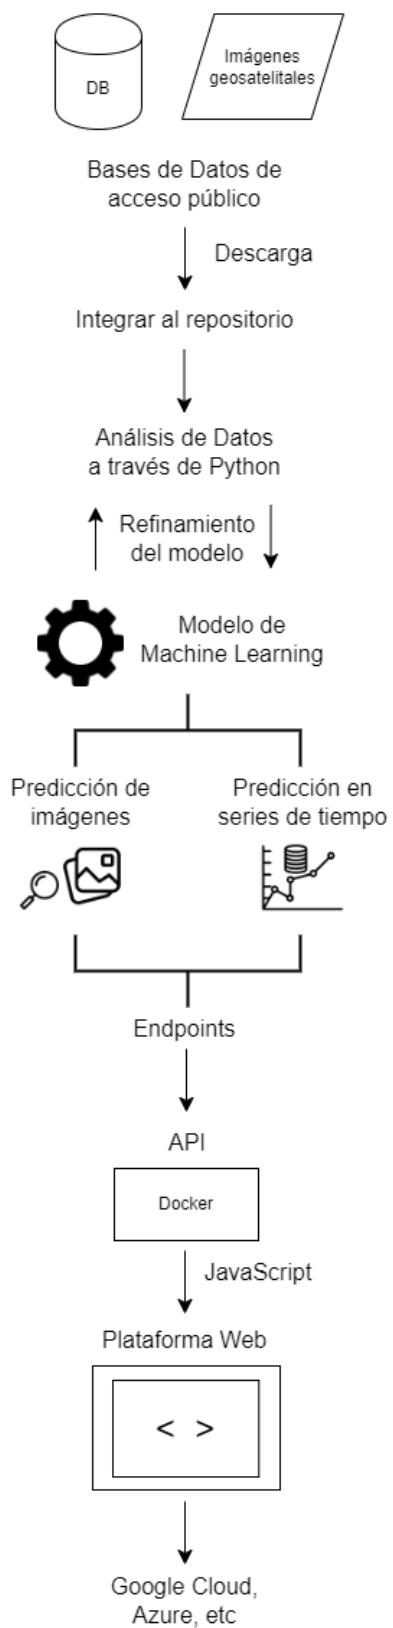
con un bien económico.

Estos fenómenos generan problemas de causa social y económica. De acuerdo a la **Organización Mundial de la Salud (OMS)**, una persona requiere de 100 litros de agua al día para satisfacer sus necesidades, tanto de consumo como de higiene. Por lo que nuestro proyecto tiene como objetivo mitigar este serio problema.

## 2. Descripción del prototipo.

- La aplicación web utiliza imágenes satelitales para detectar zonas con potencial para el aprovechamiento del agua.
- Sugiere a empresas y a particulares la opción del uso de sistemas de recolección pluvial en las áreas seleccionadas por la aplicación. Con esto, se da un estimado sobre el ahorro que el uso de nuestras recomendaciones puede traer a la empresa.
- Utilizamos bases de datos públicas sobre precipitación de lluvia para elaborar series de tiempo complejas y complementa con probabilidades de sequía a largo plazo.
- Ofrece entonces recomendaciones para contrarrestar los efectos que las sequías tendrán, siendo el más atractivo las zonas de aprovechamiento del agua por medio de la recolección pluvial.
- También la plataforma ayudara a:
  - **Gestión de Recursos Hídricos:** Ayudar a las autoridades a planificar y gestionar los recursos hídricos de manera más eficiente.
  - **Agricultura:** Proveer a los agricultores con información para tomar decisiones sobre riego y cultivo.
  - **Planificación Urbana y Rural:** Asistir en la planificación del uso del suelo y la infraestructura para mitigar los efectos de las sequías.

Arquitectura:



**Figura 2:** Arquitectura del proyecto

### 3. Desarrollo del proyecto

#### 3.1. Obtención de las bases de datos

En este proyecto tenemos dos ejes centrales sobre los que se trabaja, el primero resulta en el cálculo de series de tiempo para realizar predicciones sobre sequías y precipitaciones en distintas regiones a lo largo de la República Mexicana, con lo cual obtuvimos datos del instituto responsable del manejo del agua en nuestro país, siendo este la Comisión Nacional del Agua (CONAGUA). El segundo eje del proyecto es el análisis de imágenes satelitales para la identificación de potenciales áreas en las que se podría aprovechar la captación pluvial, en este caso las imágenes se obtuvieron manualmente a través de la plataforma QGIS y se etiquetaron los techos a través de la página Roboflow para entrenar una red neuronal para su identificación.

##### Base de datos: Monitor de Sequía

La CONAGUA creó en 2002 el Monitor de Sequía en México (MSM), dentro de las actividades del Monitor de Sequía de América en Norte. Con esta herramienta, que no tuvo un alcance nacional hasta 2014, se encargan de medir de forma quincenal las condiciones climáticas e hidrológicas de cada municipio en la República Mexicana, estableciendo categorías y niveles de sequía haciendo uso de la opinión de expertos locales y los siguientes parámetros:

- Índice Estandarizado de Precipitación (SPI): el cuál cuantifica las condiciones de déficit o exceso de precipitación.
- Anomalía de Lluvia en Porcentaje de lo Normal.
- Índice Satelital de Salud de la Vegetación (VHI) que mide el grado de estrés de la vegetación a través de la radiancia observada.
- Modelo de Humedad del Suelo Leaky Bucket CPC-NOAA que estima la humedad del suelo mediante un modelo hidrológico de una capa.
- Índice Normalizado de Diferencia de la Vegetación (NDVI).
- Anomalía de la Temperatura Media.
- Porcentaje de Disponibilidad de Agua en las persas del país.

Con estos se determinan 5 niveles de sequía, los cuales representan lo siguiente:

<b>D0</b>	<b>Anormalmente Seco:</b> Se trata de una condición de sequedad, no es una categoría de sequía. Se presenta al inicio o al final de un periodo de sequía. Al inicio de un período de sequía: debido a la sequedad de corto plazo puede ocasionar el retraso de la siembra de los cultivos anuales, un limitado crecimiento de los cultivos o pastos y existe el riesgo de incendios. Al final del período de sequía: puede persistir déficit de agua, los pastos o cultivos pueden no recuperarse completamente.
<b>D1</b>	<b>Sequía Moderada:</b> Se presentan algunos daños en los cultivos y pastos; existe un alto riesgo de incendios, bajos niveles en ríos, arroyos, embalses, abrevaderos y pozos, se sugiere restricción voluntaria en el uso del agua.
<b>D2</b>	<b>Sequía Severa:</b> Probables pérdidas en cultivos o pastos, alto riesgo de incendios, es común la escasez de agua, se deben imponer restricciones en el uso del agua.
<b>D3</b>	<b>Sequía Extrema:</b> Pérdidas mayores en cultivos y pastos, el riesgo de incendios forestales es extremo, se generalizan las restricciones en el uso del agua debido a su escasez.
<b>D4</b>	<b>Sequía Excepcional:</b> Pérdidas excepcionales y generalizadas de cultivos o pastos, riesgo excepcional de incendios, escasez total de agua en embalses, arroyos y pozos, es probable una situación de emergencia debido a la ausencia de agua.

Figura 3: Niveles de sequía delimitados por la MSM

##### Base de datos: Precipitación media por estado de la república

Esta base de datos contiene los datos de precipitación desde 1985 hasta 2023 de la precipitación media mensual de cada estado de la República Mexicana. Sus registros mensuales nos permitirán estimar la captación de agua que se tendría en un recolector pluvial en diferentes temporadas del año, y aunar estos conocimientos con la determinación de los riesgos de sequías nos permiten proponer soluciones a los usuarios de nuestra plataforma.

Las bases de datos tienen el siguiente formato:

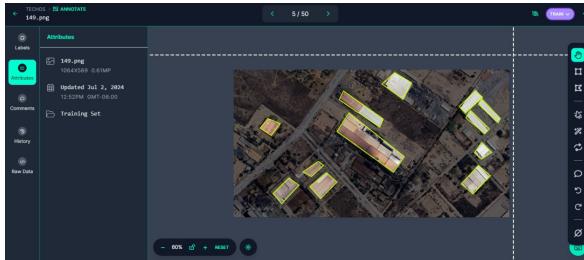
ESTADO	PRECIPITACIÓN A NIVEL NACIONAL Y POR ENTIDAD FEDERATIVA												
	ENE	FEB	MAR	ABR	MAY	JUN	JUL	SEP	OCT	NOV	DIC	ANUAL	
AGUASCALIENTES	31.5	28.4	1.5	4.6	17.3	72.6	162.8	77.3	81.9	4.5	0.0	8.9	459.4
BAJA CALIFORNIA	4.3	10.5	62.4	11.0	0.6	0.0	1.1	0.5	1.1	0.5	3.9	6.9	103.5
BAJA CALIFORNIA SUR	1.9	0.8	36.9	0.2	0.0	0.8	6.6	22.4	17.0	3.6	1.0	3.1	103.0
CAMPECHE	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	50.0
CHIHUAHUA	11.3	2.0	23.6	7.3	0.0	44.5	10.0	0.0	0.0	0.4	2.8	4.1	117.9
COAHUILA	80.3	112.1	0.0	0.0	2.1	84.7	354.0	664.3	339.2	27.0	0.0	0.7	1,665.1
COLIMA	29.4	46.1	21.0	32.4	239.6	695.1	1302.5	345.9	379.1	251.0	159.1	38.3	2,167.9
CHIAPAS	6.0	20.4	27.3	3.3	6.2	19.2	82.8	32.4	49.1	0.1	1.5	12.4	260.8
CIUDAD DE MÉXICO	13.7	1.3	21.1	22.1	32.9	19.5	184.7	231.0	231.0	20.1	0.0	0.0	537.7
DURANGO	16.9	18.7	2.3	1.0	5.6	31.1	143.9	45.9	115.1	1.9	0.3	3.6	350.4
GUANAJUATO	5.6	20.5	12.1	6.7	27.7	104.5	111.1	108.9	65.9	4.7	1.3	1.7	475.5
GUERRERO	4.0	6.0	2.9	7.8	11.9	133.0	179.0	307.3	226.4	43.2	4.5	2.7	928.0
HIDALGO	34.5	9.6	6.9	39.3	46.0	64.4	60.9	80.8	111.0	21.1	22.0	4.4	501.5
JALISCO	7.8	9.0	16.2	29.3	26.6	115.4	189.2	184.5	150.6	29.2	3.5	3.3	758.9
ESTADO DE MÉXICO	6.8	8.0	16.2	29.3	26.6	115.4	189.2	184.5	150.6	29.2	3.5	3.3	758.9
MICHOACÁN	6.8	25.8	9.0	5.1	9.8	92.5	155.2	201.0	167.6	20.2	2.9	2.4	703.0
MORELIA	0.4	61.1	0.1	0.8	9.8	93.3	101.8	349.5	231.2	30.2	0.0	0.0	1,440.5
NAYARIT	12.0	1.3	2.5	27.1	82.1	174.4	118.9	118.9	118.9	2.7	2.8	4.0	535.5
NUEVO LEÓN	29.5	17.0	2.8	25.9	63.9	148.6	189.1	303.2	239.2	66.0	51.7	10.1	1,125.6
PUEBLA	25.9	12.5	9.6	41.3	69.5	171.0	172.2	238.0	285.1	40.5	29.5	7.9	1,104.4
QUERÉTARO	23.7	12.5	19.3	17.2	34.4	66.4	83.3	58.6	70.3	33.4	6.6	1.3	407.0
QUINTANA ROO	9.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1,077.7
SAN LUIS POTOSÍ	29.0	6.0	8.6	28.1	47.1	65.4	96.2	54.8	81.3	5.6	15.6	2.8	446.3
SINALOA	21.4	54.9	3.0	1.7	2.3	14.9	221.8	162.3	150.6	6.4	1.9	12.3	533.4
SONORA	9.2	25.6	2.1	2.5	7.8	12.0	93.5	74.0	17.0	0.2	1.8	16.4	343.0
TAMAULIPAS	75.3	137.8	18.8	36.3	281.7	392.9	460.1	460.1	550.4	501.4	173.3	31.7	2,017.9
TLAXCALA	9.8	1.1	3.3	34.9	46.0	64.0	123.4	106.1	114.9	31.5	3.8	0.6	330.4
VERACRUZ	85.2	56.7	8.1	50.7	135.6	210.8	107.5	243.5	282.2	123.1	189.5	48.6	1,546.6
YUCATÁN	29.5	8.0	4.2	23.4	194.8	531.0	121.1	144.9	166.5	402.7	103.3	51.6	1,802.2
ZACATECAS	27.4	19.1	2.1	2.0	21.5	13.8	26.4	153.0	311.4	40.5	3.7	0.3	446.3
NACIONAL	21.6	22.7	21.0	40.0	53.9	109.7	120.0	122.3	178.2	65.5	36.6	7.0	722.8

Figura 4: Precipitación media mensual en 2020

##### Base de datos: Imágenes Satelitales

Para la obtención nuestras imágenes satelitales contamos con la ayuda del software QGIS que nos permite unir los mapas que proporciona Open Street Maps (OSM) que contienen la información de las calles, municipios, estados, entre otros, con los mapas de Google Satellite cuyas imágenes son las que emplearemos para la detección de techos.

Puesto que todos los datos fueron seleccionadas por nosotros, se buscó un buen nivel de diversidad de regiones. Obteniendo imágenes de diferentes estados a lo largo de la República Mexicana con zonas urbanas, rurales e industriales. De esta forma la red estará preparada para afrontar cualquier región que se le presente.



**Figura 5:** Etiquetado manual de las imágenes satelitales

Posterior a seleccionar un total de 149 imágenes satelitales con escala 1:5000 comenzamos con el etiquetado de estas. Por medio de la pagina web Roboflow, una a una seleccionamos los techos más grandes y que se ven con más claridad encontrados en la zona. Sobre todo empleamos estos criterios al momento de elegir los techos en zonas urbanas, donde en ocasiones hay mucho de donde elegir. Al final, Roboflow nos proporciona un pequeño código que se usa para descargar directamente la base de datos con el formato que requiere el algoritmo que usaremos para la detección.

### 3.2. Modelos de Predicción:

Los modelos de predicción que únicamente utilizan los datos de la **CONAGUA** e **INEGI** tienen el objetivo de complementar el núcleo principal de nuestro proyecto que es una red neuronal convolucional **YOLO** que detecta zonas potenciales para la instalación de sistemas de captación de lluvia en regiones distintas. (Mas adelante se abordara el **Núcleo** de nuestro proyecto).

Dado que nuestros modelos deben de entender los históricos de sequías y precipitaciones en cada municipio y estado de México, utilizamos las siguiente implementaciones de **Machine Learning**.

### 3.3. Sistema 1: Cadena Oculta de Markov para la modelación de las categorías de tipo de sequías.

Para este caso utilizamos la base de datos del **Monitor de Sequía**, cuyos parámetros se explican en la **Figura 3** donde se realizo un registro de niveles de sequía que se toman en cuenta como datos categóricos.

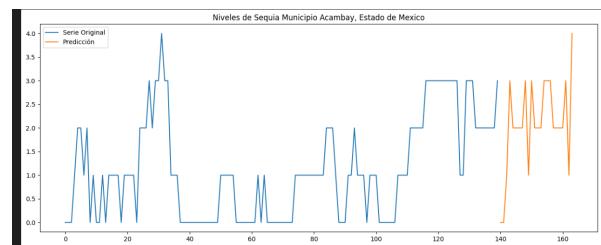
Para esto usamos una *Hidden Markov Model* ya que queremos modelar un proceso estocástico

con el objetivo de describir un sistema de estados ocultos. El modelo consta de lo siguiente:

- Un conjunto de estados no observables  $Q$ . Como los niveles son categóricos, cada estado corresponde a un valor específico en el espacio categórico. El modelo se caracteriza por el triplete  $(\pi, A, B)$ .
- Las observaciones  $O$  son las secuencias visibles generadas por los estados ocultos. Cada observación pertenece a un conjunto finito de valores.
- La matriz de transición de estados  $A = \{a_{ij}\}$  define la probabilidad de transición de un estado oculto  $i$  a otro estado oculto  $j$ .
- La matriz de emisión  $B = b_j(k)$  que define la probabilidad de observar un símbolo  $k$  (nivel de sequía) en el estado oculto  $j$ .
- La distribución inicial  $\pi = \{\pi_i\}$  define la probabilidad de que el sistema comience en el estado oculto  $i$ .

La misma librería utiliza el algoritmo de **Baum-Welch** para ajustar iterativamente los parámetros del modelo. Este proceso implica una etapa de Expectación donde se calcula la probabilidad esperada de estar en un estado dado en un tiempo dado, utilizando el algoritmo de **Forward-Backward**. Una vez hecho esto el algoritmo pasa a la etapa de Maximización donde se reestiman los parámetros del modelo para maximizar la probabilidad esperada calculada en la etapa de expectación.

Una vez que el algoritmo hace el proceso, realiza las predicciones del proceso estocástico en el cual regresa un vector de estados de sequía codificado.



**Figura 6:** Cadena oculta de Markov, Forecast de niveles de sequía

Aquí el eje  $x$  muestra el histórico de niveles de sequía desde el año 2003 hasta la actualidad, y el eje  $y$  muestra los niveles de sequía del 0-4, el cual representan los estados  $D0, D1, D2, D3$ , y  $D4$  respectivamente. Este forecast de niveles categóricos nos permite predecir un semáforo para la región y

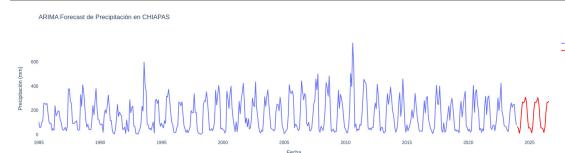
poder realizar una mejor recomendación de instalación de sistemas de captación de agua de lluvia así como otros consejos.

Estos resultados se aplican para **todos** los municipios de **todos** los estados del país.

### 3.4. Sistema 2: GridSearch de parametros ARIMA/SARIMA para la predicción de precipitacion de agua de lluvias

En el segundo sistema ahora utilizamos los datos de las precipitaciones medias en todo el país cuyo registro son desde 1985 hasta la actualidad.

Un modelo **ARIMA** (Modelo autorregresivo integrado de medias móviles). Es un modelo predictivo que utiliza variaciones y regresiones de datos estadísticos con el fin de encontrar patrones para una predicción hacia el futuro. Como ya tenemos un histórico de datos de precipitación mensual, vamos a explotar este modelo con una técnica de *data science* que se llama **GridSearch**. El **GridSearch** busca los mejores parámetros del modelo de predicción, sin embargo utilizamos el **Criterio de Akaike** el cual es una medida de la calidad relativa de un modelo estadístico, para un conjunto dado de datos. Esto nos proporciona un medio para la selección de los mejores parámetros del modelo. Con base en esto podemos realizar nuestras predicciones de precipitación pluvial para los siguientes meses.



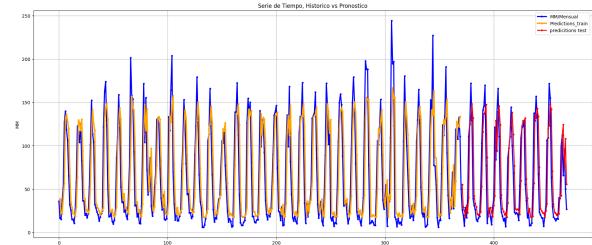
**Figura 7:** Ejemplo de Predicción de lluvia mensual, Chiapas

### 3.5. Sistema 3: Complementacion de Predicciones de lluvia por medio de LSTM (Long-Short-Term-Memory Neural Network)

Como último sistema antes de proceder al principal se utilizó una **LSTM** como un sistema alternativo a las predicciones de precipitación de agua de lluvia, esto con el objetivo de complementar aún más lo que se hizo con el **GridSearch** del modelo **ARIMA**.

Las **LSTM** son un tipo de red neuronal recurrente (RNN) diseñada para modelar secuencias y datos temporales con dependencias a largo plazo. A diferencia de las RNN tradicionales, las **LSTM** pueden aprender relaciones a largo plazo en los

datos gracias a su arquitectura especial. Para esto simplemente armamos secuencias y ventanas de observación en los históricos de precipitación de agua de lluvia nacional y complementamos las predicciones que hacían falta.

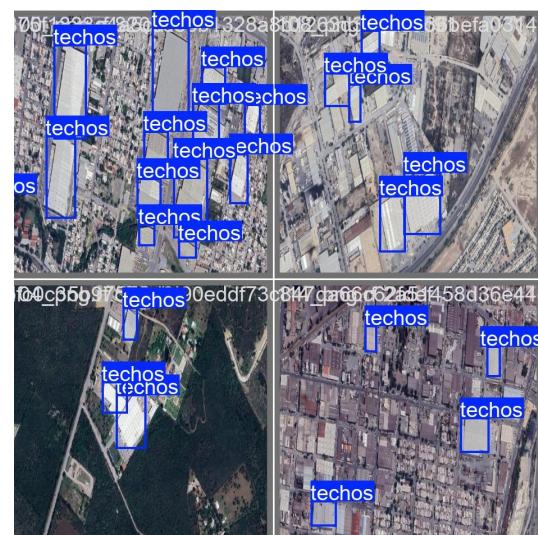


**Figura 8:** Desempeño de aprendizaje de la LSTM con el histórico Nacional de precipitación de lluvia

### 3.6. Sistema 4: Detección de áreas aprovechables por medio del modelo YOLO (You-only-look-once)

El núcleo de nuestro proyecto se encuentra en detectar techos de una región seleccionada y calcular su área con el propósito de, aunado a los sistemas vistos previamente, dar un estimado del agua de lluvia que podría obtenerse a futuro en caso de colocar sistemas de recolección pluvial en estos techos. Para lograr esto, empleamos el modelo de red neuronal **YOLO**.

**YOLO** es una de las arquitecturas más conocidas al momento de atacar el problema de detección de objetos en imágenes. **YOLO** consta de una red neuronal convolucional (CNN) que asigna un vector de pesos de probabilidad a fracciones de la imagen, de esta forma logra encontrar las zonas en la imagen donde considera es más probable se presente el objeto buscado.



**Figura 9:** Detección de techos en imágenes satelitales

Una vez contamos con el modelo, comenzamos con el entrenamiento de las 149 imágenes propias que aumentamos a 326 al invertirlas y rotarlas, de las cuales 39 las dejamos para el conjunto de prueba. Después de entrenar durante 150 épocas podemos ver algunos de los resultados en la figura 9.

Se obtuvo un 87% de precisión a la hora de seleccionar los techos marcados por nosotros en la etapa de etiquetado del conjunto de datos. La siguiente curva muestra cómo cambia la precisión con diferentes niveles de confianza. Idealmente, se desea una alta precisión en todos los niveles de confianza y se puede apreciar una tendencia a la alta de la precisión conforme avanza la confianza.

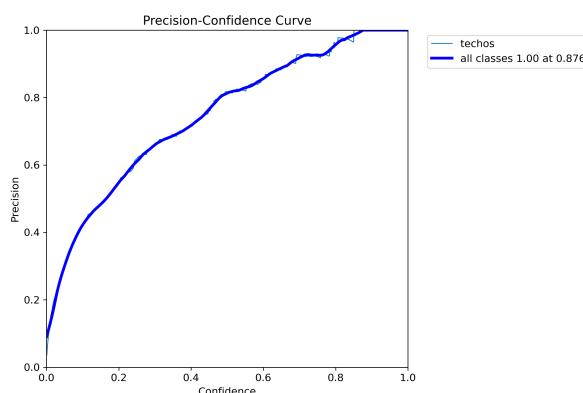


Figura 10: Nuestra curva arroja un 0.87 de precisión

La red aprendió correctamente a diferenciar los edificios en medio del campo y únicamente los techos más grandes dentro de las zonas más urbanas. Una vez contamos con un método de obtención de techos de interés, con la información obtenida se calcula el área total dentro de los rectángulos marcados para proceder con los cálculos de la cantidad de agua que se puede llegar a obtener con sistemas de recolección pluvial.

#### 4. Plataforma web

El proyecto se desplegó en una página web desarrollada en **Python** bajo el framework **Flask**.

La aplicación web presenta un mapa interactivo de Google Maps al que se accede mediante una API que se nos otorgó de manera personal y gratuita. En dicho mapa se le permite al usuario seleccionar un área de interés y gracias a los modelos de visión por computadora previamente entrenados, automáticamente se detectan los techos que se consideran más óptimos para instalar un sistema de recolección pluvial.



Figura 11: Pantalla principal

Posteriormente, a partir del área detectada, se realizan y muestran cálculos de los beneficios que podrían llegar a obtenerse, información sobre la precipitación promedio y predicción de sequías de la zona gracias a los modelos de aprendizaje profundo realizados previamente.



Figura 12: Resultados de la zona seleccionada

Se acompaña dicha información con gráficas educativas acerca de las tendencias encontradas.

#### 5. Siguientes pasos

A pesar de que presentamos un prototipo funcional, siempre hay espacio para la mejora, estos son algunos aspectos en los que consideramos se puede trabajar para mejorar la experiencia de nuestros usuarios y extender este proyecto a una mayor escala.

- Para poder brindar un cálculo más adecuado del agua que se obtendrá de los recolectores pluviales y el uso que se le puede dar, de acuerdo con los estándares de calidad del agua, sería importante agregar a nuestro análisis datos de las temperaturas por región y los

niveles de contaminación, datos que nos pueden permitir determinar con una mejor exactitud el porcentaje de agua que si se podrá utilizar, y aconsejar mejor al usuario sobre el uso que le podrá dar a la misma, es decir si el agua puede llegar a ser usada para consumo humano o solo para los sistemas de desagüe y riego.

- Con el propósito de hacer aún más preciso el cálculo de las regiones aprovechables, contamos con dos ideas de post procesamiento en las regiones seleccionadas por el modelo. La primera habla de eliminar el excedente de área con el uso del color predominante de los píxeles. Por otro lado, pensamos entrenar un clasificador que descarte algunos techos que no son aptos para la instalación de recolectores, como aquellos que ya cuentan con estos o tienen paneles solares.
- Por el lado de la pagina web, nos gustaría añadir una barra de buscador para colocar una ubicación en particular al momento de seleccionar tu región. Además, una sección de aprendizaje para el usuario donde se hable sobre el funcionamiento de los sistemas recolección pluvial y temas relevantes como los tipos de sequías y el impacto ambiental que todo esto conlleva.

## 6. Bibliografía.

- Posada, A., Daniel Ignacio (2021). Detección de objetos a través de imágenes satelitales: caso práctico en la planificación de desarrollo sostenible en zonas rurales de Nikki. Thesis (Master thesis), E.T.S.I. Industriales (UPM)
- Berhan, G., Hill, S., Tadesse, T.,& Atnafu, S. (2011). Using satellite images for drought monitoring: a knowledge discovery approach. Journal of Strategic Innovation and Sustainability, 7(1), 135-153.
- Ultralytics. (s.f.). Ultralytics — Revolutionizing the World of Vision AI. <https://www.ultralytics.com/>
- Jurafsky, D & Martin, J. (2024). Speech and Language Processing.
- Staudemeyer R. (2019) Understanding LSTM – a tutorial into Long Short-Term Memory, Recurrent Neural Networks. Faculty of Computer , Science Schmalkalden University of Applied Sciences

- Secretaría del Medio Ambiente de la Ciudad de México (2020). Cosechar la lluvia. Manual para instalar un sistema de captación pluvial en tu vivienda. Secretaría Del Medio Ambiente.<https://www.sedema.cdmx.gob.mx/storage/app/media/DGCPCA/ManualCosecharLaLluvia.pdf>
- Contreras Servín, C. (2005). The droughts in Mexico during the XIX Century. Investigaciones Geográficas, 1(56), 118–133. <https://www.scielo.org.mx/pdf/igeo/n56/n56a8.pdf>
- Esparza, M. (2014). La sequía y la escasez de agua en México: Situación actual y perspectivas futuras. Secuencia, 89, 193–219. [https://www.scielo.org.mx/scielo.php?script=sci\\_arttext&pid=S0186-03482014000200008](https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0186-03482014000200008)
- Esquivel, E. (2002). Lluvia y sequía en el norte de México. Un análisis de la precipitación histórica en Chihuahua. In Dialnet (pp. 24–42). Gaceta Ecológica. <https://dialnet.unirioja.es/descarga/articulo/2887467.pdf>